

DASF-Net — স্যারকে যেভাবে বোঝাবেন

Iftikhar Ahmed · Meherun Nessa Mithila · Mohammad Abdul Qayum
Department of Electrical and Computer Engineering, North South University

এই ডকুমেন্টটা presentation-এর script। Technical term-গুলো ইংরেজিতেই রাখা হয়েছে, কারণ ওগুলো বাংলা করলে স্যার বরং confuse হবেন। নীল দাগ দেওয়া অংশগুলো ছব্ব মুখে বলার জন্য।

১. শুরুতে এক লাইনে বলবেন

“স্যার, আমাদের কাজটা audio deepfake detection নিয়ে। এখনকার detector-গুলো দুইভাবে fail করে — নতুন ভাষায় নিয়ে গেলে কাজ করে না, আর adversarial noise দিলে ভেঙে পড়ে। **আমাদের claim হলো এই দুইটা আসলে একই সমস্যা**, আর আমরা একটাই architecture দিয়ে দুইটাকেই attack করছি।”

এইটাই পুরো paper-এর মূল কথা। বাকি সবকিছু এই এক কথাটাকে দাঁড় করানোর যন্ত্রপাতি।

২. কোথা থেকে এসেছে — দুইটা paper

প্রথম paper — BanglaFake (ঢাকা বিশ্ববিদ্যালয়, ২০২৫)। এরা **data** দিয়েছে — প্রথম public Bengali deepfake audio dataset। ১২,২৬০টা আসল আর ১৩,২৬০টা নকল (VITS নামের end-to-end TTS দিয়ে বানানো)। **কিন্তু এরা কোনো detector train করেনি**। শুধু MOS দিয়ে audio-র quality মেপেছে (naturalness ৩.৪০, intelligibility ৪.০১) আর t-SNE plot দেখিয়েছে যেখানে আসল-নকল প্রচুর overlap করে।

দ্বিতীয় paper — আমাদের নিজেদের আগের কাজ (Mel-Spectrogram for CNN, NSU)। এরা **method** দিয়েছে — দেখিয়েছে যে CNN-এর জন্য dense log-Mel, sparse LFCC-র চেয়ে ভালো (EER ০.০৩৪ বনাম ০.০৫৩, মানে ৩৬% improvement), আর adaptive FGSM/PGD training দিয়ে robustness ফিরে পাওয়া যায় (FGSM ০.৭০ → ০.১০৭)। **কিন্তু ওটা শুধু ইংরেজি ছিল**, একটা dataset-এ, আর Mel আর LFCC-কে either/or হিসেবে দেখেছে।

তৃতীয়টা আমাদের না, কিন্তু গুরুত্বপূর্ণ — “Zero-Shot to Zero-Lies” (ICCI 2025)। এরাই প্রথম BanglaFake-এ detector benchmark করেছে। কিন্তু result খুব দুর্বল — zero-shot-এ ৪৬.২০% EER, fine-tune করেও ২৪.৩৫% EER। **আর এরা নিজেরাই লিখে গেছে যে cross-lingual transfer আর adversarial robustness — এই দুইটা open problem**। আমরা ঠিক এই দুইটাতাই হাত দিচ্ছি।

এই dataset pairing-টা কেন interesting

স্যারকে এইটা আলাদা করে বলবেন, কারণ এইটা আমাদের setup-এর সবচেয়ে সুন্দর দিক:

“WaveFake-এর নকলগুলো ৭টা **GAN vocoder** দিয়ে বানানো — ওরা আসল speech-এর feature থেকে waveform আবার বানায়। আর BanglaFake-এর নকল **VITS end-to-end TTS** — সরাসরি text থেকে speech বানায়। তাই ইংরেজি → বাংলা গেলে **ভাষা আর synthesis paradigm দুইটাই একসাথে বদলায়**। এটা যেকোনো একটার চেয়ে অনেক কঠিন আর বাস্তবসম্মত test।”

৩. আসল সমস্যাটা কী (এইটা ভালো করে বলবেন)

সাধারণত লোকে বলে — “detector নতুন ভাষায় কাজ করে না মানে আরও data লাগবে।” আমরা বলছি এই ব্যাখ্যাটা ভুল।

“স্যার, detector-টা আসলে **ভুল জিনিস শিখে ফেলেছে**। ওর feature-এ ধরা পড়ছে কোন corpus, কোন speaker, কোন ভাষা — কিন্তু ধরা পড়ছে না synthesizer-টা আসলে কী করেছে।”

এখন adversarial attack-এর দিকে তাকান। FGSM/PGD কাজ করে input space-এ একটা ছোট direction খুঁজে বের করে যেটা decision উল্টে দেয়। **সেটাও একই জিনিস** — model একটা ঠুনকো, আকস্মিক জিনিসের উপর নির্ভর করছে।

তাহলে দুইটাই = model একটা nuisance direction ধরে বসে আছে।

আর machine learning-এ “এই direction-টা ব্যবহার বন্ধ করো” শেখানোর standard উপায় হলো — ওই direction-টাকে শাস্তি দেওয়ার জন্য একটা **adversary** লাগিয়ে দেওয়া।

Nuisance	সমাধান
ভাষা / corpus-এর পরিচয়	Domain-adversarial training (Gradient Reversal Layer)
Local exploitable gradient	FGSM/PGD adversarial training
“audio deepfake detection-এ এই দুইটা adversary একসাথে একই embedding-এ কেউ বসায়নি। এইটাই আমাদের gap।”	

8. DASF-Net — অংশে অংশে

নাম: **Dual-Adversarial Spectral-Fusion Network**। Figure ১, ২, ৩ দেখাতে দেখাতে বলবেন।

8.1 HBP preprocessing (High-Band-Preserving)

“আমরা audio-টা ওর native **22.05 kHz**-এই রাখছি, 16 kHz-এ নামাচ্ছি না।”

কেন গুরুত্বপূর্ণ: 16 kHz করলে Nyquist ceiling 8 kHz হয়ে যায়, মানে **8–11 kHz band পুরো মুছে যায়** — আর ঠিক ওখানেই vocoder আর TTS-এর artifact সবচেয়ে বেশি, আর ঠিক ওখানেই GAN আর VITS-এর পার্থক্য সবচেয়ে বেশি।

আমাদের **নিজেদের আগের paper-এই 16 kHz করা হয়েছিল**। শুধু ইংরেজির মধ্যে কাজ করলে ওটা চলত, কিন্তু cross-paradigm claim করতে গেলে এটা প্রমাণটাই মুছে ফেলে। **আর এইটা আমরা ablate করছি (E4), শুধু দাবি করে ছেড়ে দিচ্ছি না।**

8.2 Dual-branch front-end

একই 8 সেকেন্ডের clip থেকে **দুইটা view**:

- **Branch-S (sparse cepstral)** — LFCC: linear filterbank (20) → DCT → ২০টা coefficient → $\Delta + \Delta\Delta$
- **Branch-D (dense spectral)** — log-Mel: ১২৮টা mel bin → log-power, **DCT নাই** → $\Delta + \Delta\Delta$

দুইটার STFT setting হুবহু এক ($n_{\text{fft}} = 2048$, hop = 512)। **এইটা ইচ্ছাকৃত** — তাহলে দুইটার মধ্যে যা পার্থক্য, সেটা শুধু filterbank-এর কারণে, অন্য কিছু কারণে না।

8.৩ Siamese-shared Xception trunk

প্রতিটা branch-এর নিজের ছোট **adapter stem** (২টা conv layer, $\approx 0.06M$ parameter), তারপর **দুইটাই একই Xception backbone-এর ভেতর দিয়ে যায়, tied weights সহ**।

স্যার এইটা নিয়ে প্রশ্ন করবেন। উত্তর তৈরি রাখেন:

“দুইটা আলাদা backbone দিলে প্রতিটা branch নিজের নিজের private feature space বানাতে, আর তখন fusion module-কে দুইটা সম্পূর্ণ অসম্পর্কিত geometry মেলাতে হতো। **একটা trunk জোর করে দুইটা view-কে একটাই artifact space-এ ফেলে**, আর খরচ মাত্র $0.12M$ extra parameter — দ্বিতীয় একটা 23M model-এর বদলে।”

8.8 CASF — Cross-Attention Spectral Fusion (এইটাই মূল contribution)

১০০টা token, ২৫৬ dimension। তারপর **দুইমুখী cross-attention** — Mel view LFCC view-কে query করে, আবার LFCC view Mel view-কে query করে। শেষে একটা **learned gate**:

$$g = \sigma(W_g \cdot [\hat{h}_D; \hat{h}_S]), \quad z = g \odot \hat{h}_D + (1 - g) \odot \hat{h}_S$$

“শুধু concatenate করলে সেটা ধরে নিতো যে দুইটা view সবসময় সমান গুরুত্বপূর্ণ। **Gate দিলে network নিজে ঠিক করে — প্রতিটা utterance-এ, প্রতিটা dimension-এ — কোন representation-টা artifact বহন করছে।**”

আর একটা bonus আছে, এইটা অবশ্যই বলবেন:

“এই gate-টা model-কে interpretable করে দেয়। Test set-এ g -এর distribution দেখলেই সরাসরি উত্তর পাওয়া যায় — GAN vocoder আর end-to-end TTS কি আলাদা representation-এ চিহ্ন রেখে যায়? আমাদের আগের paper শুধু accuracy-র পার্থক্য বলতে পারত, এইটা **mechanism** বলতে পারে।”

8.৫ তিনটা head

Head	কী predict করে	কাজ
h_{det}	আসল না নকল	মূল কাজ
h_{syn}	{real, GAN-vocoder, E2E-TTS}	auxiliary
h_{lang}	ইংরেজি না বাংলা	GRL-এর পেছনে

খেয়াল করবেন h_{syn} **family** predict করে, নির্দিষ্ট generator না। ঠিক কোন generator সেটা predict করতে বললে model generator-এর identity মুখস্থ করে ফেলবে — আর সেটাই তো ওই failure যেটা cross-vocoder transfer ভেঙে দেয়।

8.৬ GRL — এইটা সবচেয়ে ভালো করে বুঝে যাবেন

স্যার সবচেয়ে বেশি সম্ভাবনা এইটা নিয়েই খোঁচাবেন।

“Gradient Reversal Layer forward pass-এ কিছুই করে না — identity। কিন্তু backward pass-এ gradient-কে $-\lambda_d$ দিয়ে গুণ করে দেয়।

ফলে যা হয়: h_{lang} প্রাণপণে চেষ্টা করে ইংরেজি আর বাংলা আলাদা করতে, **আর ঠিক সেই সময়ে shared trunk-কে ঠেলা হচ্ছে যাতে সেই আলাদা করাটা অসম্ভব হয়ে যায়।**

Converge করার পর embedding-এ থেকে যায় যা আসল-নকল আলাদা করে, আর মুছে যায় যা বাংলা-ইংরেজি আলাদা করে।”

৪.৭ পুরো objective

$$L_{\text{total}} = L_{\text{det}}(x) + \lambda_{\text{adv}} L_{\text{det}}(x + \delta) + \lambda_{\text{syn}} L_{\text{syn}} - \lambda_d L_{\text{lang}}$$

দুইটা adversary, কিন্তু প্রকৃতিতে আলাদা:

- **Perturbation adversary — local**। প্রতিটা input-এর আশেপাশের ছোট এলাকায় খোঁজে এমন direction যেটা decision উল্টে দেয়।
- **Domain adversary — global**। পুরো embedding-এ খোঁজে এমন যেকোনো direction যেটা corpus-এর পরিচয় ফাঁস করে।

“আমাদের hypothesis হলো এরা একে অপরকে সাহায্য করে — যে embedding থেকে ভাষার পরিচয় মুছে গেছে, সেখানে attack-এর জন্য কম spurious direction থাকে। তবে আমরা এটা ধরে নিচ্ছি না — ablation দিয়ে test করছি।”

৪.৮ তিন-ধাপের curriculum

একসাথে সব train করলে unstable হয় — untrained discriminator থেকে আসা reversed gradient বড় আর অর্থহীন, আর untrained boundary-র বিরুদ্ধে বানানো adversarial example স্রেফ noise। তাই:

Stage	কী হয়	কেন
১. Warm-up	Trunk frozen, শুধু adapter + CASF + h_{det}	Pretrained weight নাড়ার আগে একটা stable fused representation পাওয়া
২. Alignment	Trunk unfreeze, $h_{\text{syn}} + h_{\text{lang}}$ লাগানো, unlabelled target audio মেশানো, λ_d ধীরে বাড়ানো	ভাষা-নিরপেক্ষতা তৈরি করা
৩. Hardening	Adaptive FGSM/PGD যোগ, GRL চালু রেখেই	আগে থেকেই language-invariant এমন representation-কে শক্ত করা

Stage 2-এ **target-এর label** কখনো ব্যবহার করা হয় না — শুধু ভাষার tag। এইটা জোর দিয়ে বলবেন, এতে setting-টা target domain-এর দিক থেকে সৎভাবে unsupervised থাকে।

৫. দুইটা methodology fix — এগুলো reviewer সবচেয়ে বেশি respect করে

৫.১ CCEP — Confound-Controlled Evaluation Protocol

“স্যার, BanglaFake-এ একটা সমস্যা আছে যেটা এখনো কেউ ধরেনি — **নকল দিকটা একজন পুরুষ speaker, আর আসল দিকটা সাত জন, নারী-পুরুষ দুই-ই।**

মানে একটা model শুধু **gender classify করেই** দুর্দান্ত score পেয়ে যেতে পারে — deepfake নিয়ে কিছু না শিখেই।”

তার উপর WaveFake-এ fake:real প্রায় 8:1, আর BanglaFake-এ 1:1 — তাই accuracy দুইটার মধ্যে তুলনীয়ই না। তাই আমাদের প্রতিটা number-এ চারটা শর্ত:

1. **Speaker-disjoint split** — কোনো speaker train আর test দুই জায়গায় থাকবে না
2. **Gender-balanced Bengali evaluation** — মূল test set শুধু পুরুষ real speech; mixed-gender number আলাদা করে diagnostic হিসেবে। **দুইটার মধ্যে বড় ফারাক থাকা মানেই gender short-cut ধরা পড়েছে।**
3. **Prior-matched test set** — দুইটাই 1:1

4. EER-ই headline metric (threshold-free)

৫.২ Adversarial threat model ঠিক করা

এইটা সাহসের সাথে বলবেন, লুকাবেন না:

“আমাদের নিজেদের আগের paper-এ FGSM চালানো হয়েছে $\epsilon \approx 0.001$ -এ আর PGD চালানো হয়েছে $\epsilon \approx 0.1$ -এ — budget-এ ১০০ গুণ পার্থক্য। তাহলে ‘FGSM ০.১০৭ বনাম PGD ০.১৫৪’ — এই তুলনাটার কোনো অর্থ নেই। ভিন্ন budget দিয়ে কোন attack বেশি শক্তিশালী সেটা বলা যায় না।

আমরা দুইটা attack-কেই একই ϵ grid {0.001, 0.005, 0.010}-এ এনেছি, normalised feature domain-এ define করেছি, আর প্রতিটা ϵ -এর জন্য আলাদা করে report করছি।”

নিজেদের আগের কাজের ভুল নিজে ধরা — এটা defence-এ ভালো দেখায়, খারাপ না। মালিকানা নিয়ে বলবেন।

৬. কী কী run করব

তিনটা research question:

- **RQ1** — Bengali VITS audio-তেও কি dense > sparse? আর learned fusion কি দুইটার যেকোনো একটার চেয়ে ভালো?
- **RQ2** — dual-adversarial objective ইংরেজি ↔ বাংলা zero-shot gap কতটা কমায়?
- **RQ3** — এক ভাষায় শেখা robustness কি অন্য ভাষায় টিকে থাকে?

পাঁচটা experiment: E1 (in-language baseline), E2 (zero-shot transfer, দুই দিকেই), E3 (robustness transfer), **E4 (ablation)**, E5 (gate analysis)।

“E4-ই এইটাকে paper বানায়, demo না। Ablation ছাড়া যেকোনো improvement unattributed থেকে যায়; ablation থাকলে আমরা বলতে পারি কোন component-টা ওই improvement এনেছে।”

৭. স্যার এই প্রশ্নগুলো করবেন — উত্তর তৈরি রাখেন

Q: “এটা তো পুরনো pipeline নতুন dataset-এ চালানো, তাই না?”

“স্যার, আগের draft-এ ঠিক এই সমস্যাটাই ছিল এবং সেটা ন্যায্য সমালোচনা। ওই version-এ Mel/Xception pipeline অপরিবর্তিত রেখে শুধু transfer gap মাপা হয়েছিল। এই version-এ যোগ হয়েছে একটা fusion module, দ্বিতীয় একটা adversary, shared-trunk two-branch encoder, আর একটা training curriculum। এটা gap-টা মাপে না, কমায়।”

Q: “Wav2Vec2 বা বড় pretrained speech model fine-tune করলেই তো হতো?”

“সেটাই Zero-Shot to Zero-Lies-এর baseline, আর ওটা fine-tune করে ২৪.৩৫% EER-এ পৌঁছেছে। আমাদের claim architecture নিয়ে, scale নিয়ে না — আসল কথা হলো embedding থেকে ভাষার তথ্য সরিয়ে ফেলা, যেটা যত pretraining-ই করেন নিজে থেকে হয় না।”

Q: “GRL কি আসলে converge করে?”

“GRL unstable হওয়ার জন্য পরিচিত — ঠিক সেই কারণেই ওটা Stage 1-এ না, Stage 2-তে ঢোকানো হয়, আর λ_d fixed না রেখে standard DANN schedule দিয়ে ০ থেকে ধীরে বাড়ানো হয়। তারপরও যদি unstable হয়, সেটা method সম্পর্কে একটা reportable negative result — লুকানোর মতো bug না।”

Q: “বাংলায় তো মাত্র একটা generator। Generalisation claim করতে পারেন?”

“না স্যার, পারি না — এবং Limitations section-এ আমরা সেটা লিখেই দিয়েছি। একটা VITS system দিয়ে cross-paradigm transfer test করা যায়, কিন্তু বাংলার ভেতরে cross-vocoder generalisation test করা যায় না — যেটা WaveFake-এর ৭-generator leave-one-out ইংরেজির জন্য করে। **আমরা ওই claim করছিও না।** পরের ধাপ হলো BanglaFake-এ একটা Bengali FastSpeech2 বা Tacotron2 যোগ করা।”

Q: “খরচ কেমন?”

“Shared trunk প্রতি utterance-এ দুইবার চলে, তাই single-branch-এর চেয়ে প্রায় $2 \times$ forward/backward। আর Stage 3-এ PGD ($K = 10$) সবচেয়ে ভারী। **Inference কিন্তু একটা modern GPU-তে real-time-ই থাকে।**”

Q: “Hypothesis যদি ভুল হয়?”

“তাহলে E4 দেখাবে যে GRL আর adversarial stage একে অপরকে সাহায্য করছে না, আর আমরা সেটাই report করব। **Experimental design-টা এমনভাবে বানানো যে দুই ক্ষেত্রেই informative** — শুধু full model না চালিয়ে ablation চালানোর মানেই তো এটা।”

৮. শেষে — এইটা সততার সাথে বলবেন

এইটা এড়াবেন না। স্যার নিজে থেকে ধরে ফেললে অনেক খারাপ হবে।

“স্যার, স্পষ্ট করে বলি — **এখন পর্যন্ত একটাও experiment চালানো হয়নি।** কোনো result নেই, কোনো number নেই, কোনো trained model নেই।

Paper-এ ইচ্ছাকৃতভাবে Results section রাখা হয়নি, এবং abstract-এই সেটা লেখা আছে।

এটা একটা **design ও methodology paper**, যার **empirical study এখনো বাকি**। Architecture, algorithm, experimental design, threat model, evaluation protocol — এগুলো তৈরি। কোড লেখা হয়েছে, কিন্তু এই মেশিনে PyTorch install করা নেই বলে এখনো run করে দেখা হয়নি।”

এইভাবেই present করবেন। অন্যভাবে দাবি করলে মুহূর্তেই ধরা পড়ে যাবেন — আর তখন বাকি ভালো কাজটুকুও বিশ্বাসযোগ্যতা হারাবে।

বলার ক্রম (৫ মিনিটে)

1. এক লাইনের claim
2. দুইটা source paper + কেন এই pairing
3. “detector ভুল জিনিস শিখেছে”
4. Figure ১ দেখিয়ে DASF-Net-এর ৫টা অংশ
5. Figure ২-তে CASF gate + GRL বিস্তারিত
6. gender confound আর ϵ fix (এই দুইটাই আপনার সবচেয়ে শক্তিশালী point)
7. Figure ৩-এ তিন ধাপ
8. পাঁচটা experiment, E4-এ জোর
9. **status সততার সাথে**